Traducción Automática de Escenarios BDD en Lenguaje Natural a Lenguaje Intermedio de BDD mediante Técnicas de Procesamiento de Lenguaje Natural

por
Anna Paula Aimeri Vicentin

Presentado ante la FACULTAD DE MATEMÁTICA, ASTRONOMÍA, FÍSICA Y COMPUTACIÓN como parte de los requerimientos para la obtención del grado de Licenciado en Ciencias de la Computación de la

UNIVERSIDAD NACIONAL DE CÓRDOBA

MES, 2026

Directores:
Laura Brandán Briones

Este trabajo se distribuye bajo una licencia Creative Commons Atribución 4.0 Internacional

Agradecimientos

Resumen

Abstract

Índice general

1. Introducción **7**
1.1. Motivación y Contexto 7
1.2. Problema de Investigación 8
1.3. Enfoque Propuesto 9
1.4. Estructura del Documento 9
1.5. Trabajo Realizado 9

2. Marco Teórico **10**
2.1. Desarrollo Dirigido por Comportamiento 10
2.1.1. Sintaxis Gherkin 11
2.2. Pruebas Basadas en Modelos 12
2.3. Sistemas de Transición Simbólicos 13
2.4. Lenguaje Intermedio de BDD 14
2.5. Modelos de Lenguaje Grandes 14
2.6. Análisis Sintáctico y Gramáticas Formales 14
2.7. Trabajos Relacionados 14

3. Enfoque y Metodología **15**
3.1. Selección del Modelo de Lenguaje 15
3.1.1. Metodología de Evaluación 15
3.1.2. Resultados de la Evaluación Comparativa 16
3.1.3. Validación con Literatura Existente 18
3.1.4. Decisión Final 19
3.2. Selección de la Herramienta de Análisis Sintáctico 19
3.2.1. Lark: Características y Algoritmos 19
3.2.2. Adopción Industrial y Académica 20
3.2.3. Manejo de Gramáticas Ambiguas 20
3.2.4. Decisión: Earley en Lark 21
3.3. Diseño del Prompt de Traducción 21
3.3.1. Estructura del Prompt 21
3.3.2. Aprendizaje por Ejemplos 22

3.3.3. Reglas de Traducción 23
3.3.4. Formato de Intercambio 23
3.4. Construcción del Dataset 24
3.4.1. Escenarios Canónicos de Referencia 24
3.4.2. Generación Sintética de Escenarios 25

4. Implementación **26**
4.1. Arquitectura del Sistema 26
4.2. Definición de la Gramática IBDD 27
4.2.1. Estructura de la Gramática 27
4.2.2. Jerarquía de Expresiones 28
4.2.3. Soporte de Operadores 29
4.2.4. Transformación del Árbol Sintáctico 29
4.3. Módulo de Traducción 30
4.3.1. Structured Outputs de OpenAI 30
4.3.2. Inferencia Dinámica del Esquema 30
4.3.3. Procesamiento de Escenarios 31
4.4. Módulo de Validación Sintáctica 32
4.5. Módulo de Corrección Iterativa 33
4.5.1. Identificación de Casos Fallidos 33
4.5.2. Análisis de Errores 33
4.5.3. Reintento con Contexto de Error 34
4.5.4. Fusión No Destructiva y Re-validación 35
4.6. Módulo de Validación Semántica 35
4.6.1. Arquitectura Multi-capa 36
4.6.2. Capa 1: Validación por Checklist 36
4.6.3. Capa 2: Consistencia Numérica 37
4.6.4. Capa 3: Juez LLM 37

5. Evaluación **38**
5.1. Preguntas de Investigación 38
5.2. Diseño Experimental 38
5.3. Dataset 38
5.4. Métricas 38
5.5. Resultados 38
5.6. Análisis 38

6. Discusión **39**
6.1. Interpretación de Resultados 39
6.2. Limitaciones 39
6.3. Amenazas a la Validez 39

7. Conclusiones y Trabajo Futuro **40**
7.1. Trabajo Futuro 40

Capítulo 1

Introducción

1.1. Motivación y Contexto

El desarrollo de software moderno enfrenta un desafío persistente: cerrar la brecha entre la especificación del comportamiento deseado de un sistema y la generación automática de casos de prueba que validen ese comportamiento. El Desarrollo Dirigido por Comportamiento (BDD, *Behavior-Driven Development*) ha demostrado ser efectivo para capturar requisitos mediante escenarios en lenguaje natural estructurado, utilizando la sintaxis Given-When-Then del formato Gherkin. Esta aproximación facilita la colaboración entre técnicos y no técnicos, permitiendo que analistas de negocio, testers y desarrolladores compartan un lenguaje común para describir el comportamiento esperado del sistema.

Por otro lado, las Pruebas Basadas en Modelos (MBT, *Model-Based Testing*) ofrecen un enfoque riguroso y automatizado para generar casos de prueba a partir de modelos formales del sistema, como los Sistemas de Transición Simbólicos (STS, *Symbolic Transition Systems*). Estos modelos formales permiten aplicar algoritmos de generación automática de tests que garantizan cobertura sistemática y detectan comportamientos inesperados.

Sin embargo, existe una discontinuidad entre estos dos mundos. Los escenarios BDD, expresados en lenguaje natural, carecen de la precisión formal necesaria para alimentar directamente las herramientas de MBT. Investigaciones recientes han propuesto el Lenguaje Intermedio de BDD (IBDD) como puente entre ambos paradigmas [16]. IBDD mantiene la estructura Given-When-Then de BDD pero incorpora elementos formales de los STS, incluyendo variables globales y locales, guardas lógicas, gates de interacción y asignaciones explícitas de estado.

Los trabajos de Zameni et al. han demostrado que, una vez que los escena-

rios están representados en IBDD, es posible transformarlos automáticamente en Sistemas de Transición BDD (BDDTS) y posteriormente en STS, desde donde se pueden generar casos de prueba completos y formalmente válidos [17]. El paso faltante en esta cadena de automatización es precisamente la traducción inicial: convertir escenarios Gherkin escritos por humanos en representaciones IBDD formalmente correctas.

Actualmente, esta traducción es un proceso enteramente manual que requiere experiencia especializada en teoría de sistemas de transición y conocimiento profundo de la gramática IBDD. Un analista debe identificar variables implícitas, inferir gates de interacción apropiados, establecer guardas lógicas correctas y determinar las asignaciones de estado necesarias—información que típicamente no está explícita en el texto natural del escenario BDD. Este cuello de botella limita la escalabilidad industrial de todo el pipeline BDD-a-MBT.

1.2. Problema de Investigación

El problema central que aborda este trabajo es: *¿cómo automatizar la traducción de escenarios BDD expresados en lenguaje natural (formato Gherkin) al lenguaje intermedio formal IBDD, preservando la semántica del comportamiento especificado y generando representaciones formalmente válidas que puedan alimentar herramientas de generación automática de casos de prueba?*

Este problema presenta múltiples desafíos técnicos. En primer lugar, los escenarios Gherkin contienen imprecisiones inherentes al lenguaje natural que deben resolverse para producir especificaciones formales. A esto se suma que elementos cruciales de IBDD—variables globales, tipos de datos, funciones del dominio, gates del sistema—no están explícitos en el texto Gherkin y deben inferirse del contexto o del conocimiento del dominio. La correspondencia entre construcciones lingüísticas en Gherkin y elementos formales de IBDD tampoco es trivial; por ejemplo, la frase "el usuario hace clic en agregar al carrito" debe traducirse a un gate de entrada específico (`?click.add_button`) con variables de interacción apropiadas. Las traducciones generadas, a su vez, deben ser sintácticamente correctas según la gramática IBDD y semánticamente consistentes con la especificación BDD original. Finalmente, la diversidad de dominios que abarcan los escenarios BDD—e-commerce, sistemas industriales, aplicaciones financieras—introduce vocabularios y patrones de interacción específicos que el sistema debe manejar.

1.3. Enfoque Propuesto

Este trabajo propone un enfoque híbrido que combina las capacidades de comprensión semántica de Modelos de Lenguaje Grandes (LLMs, *Large Language Models*) con la estructura formal proporcionada por la gramática IBDD y técnicas de análisis sintáctico determinístico.

La arquitectura del sistema se organiza en torno a dos componentes principales. El primero es un módulo de traducción basado en LLM que utiliza modelos de lenguaje pre-entrenados para interpretar escenarios Gherkin y generar candidatos de traducción IBDD, aprovechando la capacidad de los LLMs para capturar patrones semánticos complejos y realizar inferencias sobre información implícita. El segundo componente es un módulo de validación sintáctica que emplea la biblioteca Lark con su analizador Earley para verificar las traducciones generadas contra la gramática formal IBDD, garantizando corrección estructural.

El flujo del sistema opera de la siguiente manera: un escenario Gherkin es procesado por el LLM, que genera tres candidatos de traducción IBDD; estos candidatos son luego validados sintácticamente mediante Lark. Si la validación falla, se inicia un ciclo de corrección iterativa hasta obtener una representación IBDD válida.

La elección de LLMs se fundamenta en su demostrada capacidad para tareas de traducción entre lenguajes formales y naturales, como se evidencia en trabajos recientes sobre generación de código desde especificaciones [**placeholder:llm-code-generation**] y traducción de requisitos a modelos formales [**placeholder:nl-to-formal**]. Sin embargo, los LLMs por sí solos no garantizan corrección sintáctica ni consistencia formal, de ahí la necesidad del componente de validación.

1.4. Estructura del Documento

1.5. Trabajo Realizado

Capítulo 2

Marco Teórico

Este capítulo presenta los conceptos fundamentales necesarios para comprender el desarrollo del presente trabajo. Se introducen el Desarrollo Dirigido por Comportamiento y su sintaxis Gherkin, las Pruebas Basadas en Modelos y los Sistemas de Transición Simbólicos que las sustentan, el Lenguaje Intermedio de BDD que actúa como puente entre ambos paradigmas, los Modelos de Lenguaje Grandes utilizados para la traducción automática, y las técnicas de análisis sintáctico empleadas para la validación. Finalmente, se revisan los trabajos relacionados que contextualizan esta investigación.

2.1. Desarrollo Dirigido por Comportamiento

El Desarrollo Dirigido por Comportamiento (BDD, *Behavior-Driven Development*) es una práctica de desarrollo de software que surge como evolución del Desarrollo Dirigido por Pruebas (TDD, *Test-Driven Development*). Fue propuesto por Dan North en 2006 [8] como respuesta a las dificultades que encontraban los equipos al adoptar TDD: incertidumbre sobre qué probar, cómo nombrar las pruebas y cómo entender por qué una prueba falla.

La innovación central de BDD consiste en desplazar el foco desde las pruebas hacia el comportamiento esperado del sistema. En lugar de escribir pruebas unitarias que verifican implementaciones específicas, BDD propone describir el comportamiento del sistema desde la perspectiva del usuario mediante escenarios concretos. Este cambio de vocabulario—de "prueba" a "comportamiento"—tiene implicaciones profundas: facilita la comunicación entre desarrolladores, analistas de negocio y otros *stakeholders*, y produce especificaciones que sirven simultáneamente como documentación y como base para pruebas automatizadas.

Solís y Wang [12] identifican como características fundamentales de BDD la

ubicuidad del lenguaje compartido entre todos los participantes del proyecto, la naturaleza iterativa del proceso de especificación, y el uso de ejemplos concretos como mecanismo primario de comunicación entre el dominio del negocio y el dominio técnico.

2.1.1. Sintaxis Gherkin

El vehículo principal para expresar escenarios BDD es Gherkin, un lenguaje de dominio específico diseñado para ser legible tanto por humanos como por herramientas de automatización [2]. Un escenario Gherkin describe una situación concreta del comportamiento del sistema mediante tres cláusulas estructuradas:

- **Given** (*Dado*): establece las precondiciones o el estado inicial del sistema antes de que ocurra la acción bajo prueba.
- **When** (*Cuando*): describe la acción o evento que desencadena el comportamiento que se desea especificar.
- **Then** (*Entonces*): define el resultado esperado o la postcondición que debe verificarse tras la ejecución de la acción.

A modo de ejemplo, el siguiente escenario especifica el comportamiento de un sistema de comercio electrónico al agregar un producto al carrito de compras:

Listing 2.1: Ejemplo de un escenario BDD en sintaxis Gherkin.

```
Scenario: Add product to shopping cart
  Given the user is on the product page for "Laptop"
  And the product is in stock
  When the user clicks the "Add to Cart" button
  Then the cart should contain 1 item
  And the total price should be updated
```

Los escenarios Gherkin se agrupan en archivos denominados *features*, donde cada *feature* describe una funcionalidad del sistema e incluye uno o más escenarios que ilustran su comportamiento esperado bajo distintas condiciones. Las palabras clave **And** y **But** permiten encadenar múltiples condiciones dentro de una misma cláusula, mejorando la legibilidad sin alterar la semántica de la especificación.

Esta estructura, si bien es lo suficientemente formal para ser procesada por herramientas de automatización como Cucumber, mantiene un nivel de abstracción cercano al lenguaje natural. Es precisamente esta característica la

que convierte a Gherkin en un formato accesible para *stakeholders* no técnicos, pero también la que introduce los desafíos de ambigüedad e imprecisión que motivan el presente trabajo.

2.2. Pruebas Basadas en Modelos

Las Pruebas Basadas en Modelos (MBT, *Model-Based Testing*) constituyen un enfoque de verificación de software en el que los casos de prueba se derivan de manera sistemática a partir de un modelo formal que describe el comportamiento esperado del sistema bajo prueba [14]. A diferencia de las técnicas de prueba manuales, donde un ingeniero diseña casos de prueba individualmente, MBT automatiza este proceso: dado un modelo del sistema y un criterio de cobertura, un algoritmo de generación produce un conjunto de casos de prueba que satisface dicho criterio.

Utting et al. [14] proponen una taxonomía que clasifica los enfoques de MBT según cinco dimensiones: la notación del modelo (máquinas de estados, autómatas, modelos de flujo de datos), el criterio de selección de pruebas (cobertura estructural, cobertura de requisitos, selección aleatoria), la tecnología de generación (model checking, ejecución simbólica, búsqueda), la ejecución de las pruebas (*online* versus *offline*), y el nivel de automatización del proceso completo.

En el contexto de sistemas reactivos—sistemas que interactúan con su entorno mediante estímulos y respuestas—Tretmans [13] formaliza la relación de conformidad *ioco* (*input-output conformance*) como criterio para determinar si una implementación se comporta de acuerdo con su especificación. Bajo esta teoría, el modelo del sistema se expresa como un Sistema de Transición Etiquetado (*Labelled Transition System*, LTS), y los casos de prueba se generan como secuencias de estímulos y observaciones que verifican la conformidad de la implementación con respecto al modelo.

El atractivo fundamental de MBT reside en la posibilidad de generar automáticamente grandes conjuntos de casos de prueba con garantías formales de cobertura, lo cual resulta particularmente valioso en dominios donde la exhaustividad de las pruebas es crítica. Sin embargo, la aplicación de MBT requiere la existencia de un modelo formal del sistema, cuya construcción constituye en sí misma un desafío significativo. En la tesis doctoral de Brandán Briones [1] se desarrollan teorías para MBT que abordan aspectos de tiempo real y cobertura en este tipo de sistemas.

2.3. Sistemas de Transición Simbólicos

Los Sistemas de Transición Simbólicos (STS, *Symbolic Transition Systems*) constituyen una extensión de los Sistemas de Transición Etiquetados (LTS) que incorpora una representación explícita de datos y flujo de control dependiente de datos [4]. Mientras que en un LTS los valores de datos se representan de manera concreta—lo cual conduce a una explosión del espacio de estados cuando los dominios de datos son grandes o infinitos—los STS operan a nivel simbólico, utilizando variables y fórmulas de lógica de primer orden para expresar condiciones sobre los datos.

Formalmente, un STS se define como una tupla $\langle L, l_0, V, \iota, I, \Lambda, \rightarrow \rangle$, donde [3]:

- L es un conjunto finito de *localidades* (estados de control).
- $l_0 \in L$ es la localidad inicial.
- V es un conjunto de *variables de localidad* que representan el estado del sistema.
- ι es una valuación inicial que asigna valores a las variables en V.
- I es un conjunto de *variables de interacción* utilizadas para el intercambio de datos con el entorno.
- Λ es un conjunto de *gates* (etiquetas de interacción) que representan los canales de comunicación.
- $\rightarrow \subseteq L \times \Lambda \times \Phi \times F \times L$ es la relación de *switches* (transiciones), donde Φ denota guardas lógicas y F funciones de actualización de variables.

Cada switch representa una transición entre dos localidades, condicionada por una guarda (una fórmula lógica sobre las variables de localidad y de interacción) y acompañada por una función de actualización que modifica el estado. Los gates se clasifican en gates de entrada (que reciben estímulos del entorno) y gates de salida (que emiten respuestas), reflejando la naturaleza reactiva de los sistemas modelados.

La ventaja de esta representación simbólica es doble. En primer lugar, evita la enumeración explícita de valores de datos, lo cual permite modelar sistemas con dominios infinitos sin incurrir en explosión de estados. En segundo lugar, preserva la información semántica de las restricciones sobre los datos, que puede ser explotada durante la generación de casos de prueba. Frantzen et al. [3] definen la relación de conformidad simbólica *sioco*, que extiende la

relación *ioco* de Tretmans al nivel simbólico, proporcionando una base formal para la generación de pruebas directamente desde especificaciones STS.

Los conceptos de STS resultan esenciales para comprender el lenguaje IBDD presentado en la sección siguiente, ya que IBDD adopta directamente la terminología y estructura de los STS—variables, gates, guardas y asignaciones—como elementos de su gramática formal.

2.4. Lenguaje Intermedio de BDD

2.5. Modelos de Lenguaje Grandes

2.6. Análisis Sintáctico y Gramáticas Formales

2.7. Trabajos Relacionados

Capítulo 3

Enfoque y Metodología

3.1. Selección del Modelo de Lenguaje

La tarea central de este trabajo—traducir escenarios BDD en lenguaje natural a representaciones formales IBDD—requiere un modelo de lenguaje con capacidades de comprensión semántica, generación estructurada y consistencia sintáctica. Esta sección describe el proceso de evaluación comparativa que condujo a la selección del modelo utilizado.

3.1.1. Metodología de Evaluación

Se evaluaron tres modelos de última generación: GPT-4o de OpenAI, Claude Sonnet 4 de Anthropic y Llama 3.3 70B de Meta. La selección de estos modelos responde a la diversidad de sus orígenes—propietario de uso general, propietario orientado a razonamiento, y de código abierto—y a su representatividad del estado del arte al momento de la evaluación.

La evaluación se realizó sobre un escenario de *e-commerce* que involucra interacciones típicas de sistemas web: gestión de productos, carritos de compra, inventario y sesiones de usuario. Este escenario presenta desafíos característicos de la traducción BDD→IBDD, ya que requiere identificar variables globales (inventario, carrito) y locales (producto, cantidad), inferir gates de interacción apropiados (`?click`, `?input`, `!add`, `!update`), establecer guardas lógicas para validaciones y definir asignaciones de estado correctas.

Escenario de Prueba

El escenario BDD utilizado para la evaluación fue el siguiente:

```
Scenario: A product is added to shopping cart when user selects it
  Given a product is available in inventory
```

```
And the user is logged in
When the user clicks add to cart button
And the user specifies quantity
Then the product is added to the shopping cart
And the inventory is updated
```

Diseño del Prompt

Se diseñó un prompt unificado que incorpora la definición completa de la gramática IBDD en notación EBNF, una explicación de los elementos clave del lenguaje (variables locales y globales, gates, guards y assignments), un ejemplo canónico de referencia del dominio de impresora industrial extraído de los trabajos de Zameni et al. [16], e instrucciones para generar tres opciones de traducción con enfoques diferenciados. Los criterios de evaluación abarcaron la granularidad de las interacciones, el modelado de variables, el nivel de detalle y la estructuración de estados. Este prompt se aplicó de manera idéntica a los tres modelos para garantizar la comparabilidad de los resultados. La solicitud de tres opciones por modelo permitió evaluar tanto la capacidad de traducción como la diversidad de los enfoques propuestos.

3.1.2. Resultados de la Evaluación Comparativa

Se obtuvieron nueve traducciones en total (tres opciones por cada modelo). La Tabla 3.1 resume los resultados según los criterios evaluados.

Tabla 3.1: Comparación de modelos para la traducción BDD→IBDD.

Criterio	**GPT-4o**	**Claude S. 4**	**Llama 3.3**
Corrección sintáctica	Alta	Media	Baja
Consistencia	Alta	Media	Baja
Diversidad de enfoques	Alta	Alta	Baja
Preservación semántica	Alta	Alta	Media
Calidad de justificaciones	Alta	Media	Baja

GPT-4o

GPT-4o demostró el desempeño más consistente entre los tres modelos. Las tres opciones generadas respetan la gramática IBDD sin desviaciones sintácticas, y cada una explora un paradigma técnico distinto: atómico/granular, compuesto y concurrente con reservas. El siguiente fragmento ilustra la Opción 2 (enfoque compuesto):

```
GIVEN PROD, USER [is_available(PROD, INV) ∧is_logged_in(USER)]
WHEN
    ?addToCart.prod_qty, payload
        payload.product = PROD ∧payload.qty > 0
        (PROD, QTY) := (payload.product, payload.qty)
THEN
    !persist.cart_and_inventory, result
        result.cart_after = addItem(S_CART, PROD, QTY) ∧
        result.inv_after = INV[PROD] - QTY
        CART := result.cart_after;
        INV := updateInventory(INV, PROD, QTY)
    [is_in_cart(PROD, CART) ∧INV[PROD] = INV_before(PROD) - QTY]
```

Esta traducción modela la interacción del usuario como un gate de entrada (`?addToCart`), define guardas que verifican la disponibilidad del producto y la validez de la cantidad, y establece asignaciones que reflejan las modificaciones al carrito y al inventario. El propio modelo identifica correctamente los compromisos de diseño entre las opciones, señalando por ejemplo que la tercera opción puede resultar sobredimensionada. En efecto, algunas opciones tienden a introducir niveles de complejidad que, si bien son técnicamente válidos, exceden lo requerido por el escenario, y las explicaciones que acompañan cada traducción resultan a veces verbosas.

Claude Sonnet 4

Claude exhibió creatividad conceptual en sus traducciones, con una progresión deliberada de simplicidad a complejidad entre las tres opciones, una documentación detallada de las variables utilizadas y guardas lógicas bien estructuradas. Sin embargo, la consistencia sintáctica fue inferior a la de GPT-4o. En particular, una de las opciones introduce notaciones como `BTN_STATE := clicked` que no se ajustan a las convenciones de la gramática IBDD de referencia:

```
GIVEN P, U, Q [P.available = true ∧U.logged_in = true]
WHEN ?click.add_to_cart_btn
     U.logged_in = true ∧P.available = true
     BTN_STATE := clicked
```

Si bien la traducción es conceptualmente correcta, estas desviaciones sintácticas requerirían corrección posterior para ser procesadas por el analizador IBDD.

Llama 3.3 70B

Llama 3.3 presentó las mayores limitaciones. Si bien las traducciones son breves y no contienen errores conceptuales graves, las tres opciones presentan errores sintácticos consistentes, ninguna modela la actualización de inventario (perdiendo información del escenario original), las justificaciones de diseño carecen de sustento técnico, y se confunde la dirección de los gates de interacción. El siguiente fragmento ilustra estos problemas:

```
GIVEN prod [true], user logged_in
WHEN !select_prod, ?spec_quantity
    true
    prod := p
THEN !add_to_cart.sc
    sc.product = p ∧sc.quantity = q
    SC := add(p, sc), Q := spec_quantity
    [is_in_SC(p, sc) ∧sc.product = p]
```

En esta traducción, el gate `!select_prod` (gate de salida) se utiliza para modelar una acción del usuario, cuando la semántica de IBDD establece que las acciones del usuario corresponden a gates de entrada (`?`). La combinación de un gate de salida con uno de entrada en la cláusula `WHEN` viola la estructura esperada del lenguaje.

3.1.3. Validación con Literatura Existente

Los resultados obtenidos son consistentes con hallazgos de la literatura. Karpurapu et al. [6] evaluaron varios LLMs (GPT-3.5, GPT-4, Llama-2-13B, PaLM-2) para la generación automática de tests de aceptación BDD a partir de historias de usuario. En su estudio, los modelos GPT exhibieron menor cantidad de errores sintácticos y mejor adherencia a las reglas y mejores prácticas de Gherkin al generar archivos *feature*, mientras que Llama-2-13B mostró dificultades significativas en evaluaciones *zero-shot*, con 130 instancias de palabras clave Gherkin ausentes y 335 instancias de patrones restringidos. Sus resultados también confirman que la técnica de *few-shot prompting* produce mayor precisión que *zero-shot*.

Aunque el trabajo de Karpurapu et al. aborda la dirección inversa a la de este trabajo (historias de usuario → Gherkin, frente a Gherkin → IBDD), los patrones observados son similares: los modelos GPT mantienen consistencia sintáctica superior, Llama presenta dificultades sistemáticas con formalismos sintácticos, y la provisión de ejemplos—como el caso de la impresora industrial incluido en nuestro prompt—mejora los resultados. Esta convergencia refuerza la validez de la selección realizada.

3.1.4. Decisión Final

Sobre la base de los resultados experimentales y su consistencia con la literatura, se seleccionó la familia de modelos GPT-4o de OpenAI como motor de lenguaje para el sistema de traducción. El modelo demostró corrección sintáctica en todas las traducciones generadas, alta uniformidad de calidad entre ejecuciones y capacidad de explorar enfoques alternativos genuinos. Si bien se trata de un modelo propietario que requiere acceso mediante la API de OpenAI, esta limitación se considera aceptable en el contexto de un trabajo de investigación.

Es importante señalar que la arquitectura del sistema parametriza la versión del modelo como una variable de configuración, lo que permite actualizarla sin modificar el resto de la implementación. La evaluación comparativa presentada en este capítulo se realizó con la versión `gpt-4o-2024-08-06`, disponible al momento del desarrollo. Dado que OpenAI publica periódicamente nuevas versiones dentro de la misma familia de modelos, el sistema está diseñado para incorporar versiones posteriores de forma transparente. Esta decisión de diseño asegura que los resultados de la evaluación sean reproducibles con el modelo original, al tiempo que permite beneficiarse de mejoras futuras.

Para despliegues futuros donde se requieran modelos de código abierto, los resultados sugieren que alternativas como Llama podrían ser viables incorporando mecanismos adicionales de validación y corrección.

3.2. Selección de la Herramienta de Análisis Sintáctico

La validación sintáctica de las traducciones IBDD generadas por el LLM requiere una herramienta de análisis sintáctico (*parsing*) capaz de verificar conformidad con la gramática formal IBDD. El analizador debe resolver ambigüedades sintácticas, proveer reportes de errores precisos, integrarse con Python—lenguaje de implementación del sistema—, ofrecer confiabilidad para uso en investigación, y permitir la especificación declarativa de la gramática en un formato legible.

3.2.1. Lark: Características y Algoritmos

Lark [**lark˙docs**] es una biblioteca de análisis sintáctico para Python que ha alcanzado amplia adopción tanto en la industria como en la academia. Implementa tres algoritmos principales de análisis. El algoritmo Earley logra

rendimiento lineal en casos favorables y puede procesar gramáticas ambiguas, lo que lo hace adecuado para prototipado y lenguajes de estructura compleja; su principal limitación es un rendimiento aproximadamente diez veces inferior al de LALR en gramáticas no ambiguas [**lark˙parsing˙comparison**]. El algoritmo LALR ofrece el mejor rendimiento para gramáticas no ambiguas bien definidas, aunque su *lexer* contextual puede presentar fallos en ciertos casos de ambigüedad [**lark˙issues**]. El algoritmo CYK presenta limitaciones que incluyen un defecto reportado que causa bucles infinitos con gramáticas recursivas [**lark˙issues**], por lo que no resulta apropiado para uso fuera de contextos teóricos.

El repositorio oficial de Lark [7] incluye *benchmarks* comparativos con otras bibliotecas de análisis sintáctico para Python. Según análisis independientes [5], Lark se posiciona favorablemente en el balance entre flexibilidad, rendimiento y facilidad de uso.

3.2.2. Adopción Industrial y Académica

Lark está clasificado como *Production/Stable* en PyPI, cuenta con más de 5 500 estrellas en GitHub y mantiene desarrollo activo [**lark˙pypi**]. Su adopción en sistemas de escala empresarial respalda su confiabilidad: Dailymotion procesa más de 100 millones de llamadas API GraphQL diarias utilizando Lark para el análisis de *GraphQL Schema Definition Language* [**dailymotion˙graphql**]; Vyper, el lenguaje de contratos inteligentes para Ethereum, emplea Lark para el análisis de su sintaxis [15]; y Poetry, el gestor de dependencias de Python, depende de Lark para procesar archivos de configuración [10].

En el ámbito académico, Hundvin [**hundvin2022code**] desarrolló en la Universidad de Bergen una tesis de maestría sobre generación de fragmentos de código a partir de especificaciones de gramática Lark, contribuyendo algoritmos para producir código sintácticamente correcto desde gramáticas formales. Este precedente demuestra la adecuación de Lark para investigación en análisis sintáctico y validación de lenguajes.

3.2.3. Manejo de Gramáticas Ambiguas

El analizador Earley de Lark puede almacenar eficientemente todas las ambigüedades presentes en una gramática [**lark˙docs**]. La biblioteca ofrece tres estrategias de resolución: el modo `resolve` (predeterminado) elige automáticamente la derivación más simple; el modo `explicit` retorna todas las derivaciones posibles para selección manual; y el modo `forest` retorna el bosque de análisis completo, con mayor eficiencia en memoria para gramáticas

altamente ambiguas. Esta flexibilidad resulta relevante para IBDD, donde ciertas construcciones sintácticas pueden admitir múltiples interpretaciones válidas.

3.2.4. Decisión: Earley en Lark

Se seleccionó Lark con el algoritmo Earley como herramienta de análisis sintáctico. El algoritmo Earley ofrece la flexibilidad necesaria para manejar la estructura anidada y las potenciales ambigüedades de la gramática IBDD, permite iteración ágil durante el desarrollo de dicha gramática, y cuenta con respaldo tanto industrial como académico. La gramática se especifica en formato EBNF, lo que facilita su lectura y mantenimiento, y el analizador provee información detallada sobre violaciones sintácticas que resulta útil para el ciclo de corrección iterativa.

El compromiso de rendimiento respecto a LALR—aproximadamente un orden de magnitud más lento—se considera aceptable dado que el volumen de escenarios a procesar es moderado y la corrección es prioritaria sobre la velocidad en esta fase de investigación. Para un sistema de producción futuro, la migración a LALR sería recomendable una vez estabilizada la gramática IBDD.

3.3. Diseño del Prompt de Traducción

El diseño del prompt constituye un componente central del sistema, ya que determina la capacidad del modelo de lenguaje para producir traducciones IBDD sintáctica y semánticamente correctas. Se adoptó una estrategia de *few-shot prompting* con instrucciones estructuradas, organizada en cinco componentes que proveen al modelo con el contexto completo necesario para la tarea de traducción.

3.3.1. Estructura del Prompt

El prompt se organiza en cinco secciones. La primera establece el contexto general, indicando que se traducirán escenarios Gherkin a IBDD y que este lenguaje intermedio agrega precisión formal mediante sistemas de transición simbólicos. La segunda sección incluye la gramática IBDD completa en notación EBNF, junto con la descripción de los elementos clave del lenguaje: variables locales y globales, variables de interacción, gates de entrada (`?`) y salida (`!`), guardas booleanas y asignaciones, así como el repertorio de operadores aceptados en notación Unicode y ASCII. La tercera sección provee

ejemplos de traducción resueltos con explicaciones del razonamiento aplicado. La cuarta sección especifica reglas de traducción para cada cláusula (Given, When, Then) y convenciones de nomenclatura. La quinta sección define el formato de entrada y salida esperado y las restricciones de formato del resultado.

La inclusión de la gramática formal directamente en el prompt responde a un requisito fundamental: el modelo debe conocer la sintaxis exacta del lenguaje objetivo para generar traducciones conformes. Sin esta especificación, las traducciones presentarían las desviaciones sintácticas observadas durante la evaluación comparativa de modelos, donde incluso GPT-4o introducía variaciones cuando el prompt no era suficientemente explícito respecto a las reglas de formato.

3.3.2. Aprendizaje por Ejemplos

Se adoptó la técnica de *few-shot prompting* con cuatro ejemplos canónicos que cubren los patrones más frecuentes de la traducción BDD→IBDD. Los primeros tres ejemplos provienen del dominio de impresora industrial, extraído de los trabajos de Zameni et al. [16], y el cuarto del dominio de comercio electrónico. Esta selección de dos dominios distintos busca que el modelo generalice los patrones de traducción en lugar de memorizar un formato específico de dominio.

El primer ejemplo ilustra un escenario con una única variable local declarada en la cláusula Given, precondición trivial (`[true]`), un gate de entrada en When y un gate de salida en Then con postcondición de verificación. El segundo ejemplo presenta variables locales con guardas no triviales y dos switches secuenciales en When que modelan un proceso de dos etapas. El tercer ejemplo muestra un escenario sin variables locales donde la cláusula Given contiene únicamente una guarda sobre el estado global del sistema. El cuarto ejemplo introduce múltiples variables de interacción y asignaciones compuestas que actualizan más de un atributo del estado.

Cada ejemplo incluye el escenario Gherkin original en formato JSON, la traducción IBDD correspondiente y una explicación del razonamiento que justifica las decisiones de traducción. Esta estructura permite que el modelo observe no solo el resultado esperado sino también el proceso inferencial que lo produce. La elección de *few-shot* frente a *zero-shot* es consistente con los hallazgos de Karpurapu et al. [6], quienes reportaron que la provisión de ejemplos mejora significativamente la precisión de los LLMs en tareas de generación de formalismos BDD.

3.3.3. Reglas de Traducción

El prompt especifica reglas explícitas para la traducción de cada cláusula Gherkin. Para la cláusula Given, el modelo debe identificar si el texto menciona entidades que constituyen variables locales (por ejemplo, "a job file" se traduce a la variable local `JF`) o si describe condiciones sobre el estado global del sistema, que se modelan como guardas sin declaración de variables. Múltiples condiciones se combinan mediante el operador de conjunción lógica y la guarda resultante se encierra entre corchetes.

Para la cláusula When, las acciones del usuario se modelan como gates de entrada (`?`) y las acciones del sistema como gates de salida (`!`). Cuando el texto contiene múltiples acciones conectadas por "AND", cada acción se traduce como un switch independiente. Cada switch debe incluir una condición entre corchetes y, opcionalmente, asignaciones que reflejen cambios de estado.

Para la cláusula Then, las verificaciones del estado final se expresan como postcondiciones en la guarda final, mientras que las acciones explícitas del sistema se modelan como switches con gates de salida. Las convenciones de nomenclatura establecen que las variables locales se representan como abreviaturas en mayúscula (`CJ`, `JF`, `P`), las variables globales como nombres descriptivos en mayúscula (`SJL`, `PJL`), las variables de interacción en minúscula (`cj`, `jf`, `p`) y los gates como verbos descriptivos en minúscula (`submit`, `printstart`, `add_to_cart`).

3.3.4. Formato de Intercambio

Se seleccionó JSON como formato de intercambio entre el sistema y el modelo de lenguaje, tanto para la representación de los escenarios BDD de entrada como para las traducciones IBDD de salida. Esta decisión se fundamenta en la relación entre los datos de entrenamiento de los modelos de lenguaje y su desempeño en tareas de generación estructurada. Los modelos de la familia GPT fueron entrenados sobre corpus masivos que incluyen una proporción significativa de datos en formato JSON, provenientes de repositorios de código fuente, documentación de APIs web, archivos de configuración y conjuntos de datos abiertos [**placeholder:gpt-training-data**]. Dado que estos modelos observaron millones de ejemplos de JSON bien formado durante su entrenamiento, han desarrollado una familiaridad inherente con la sintaxis de este formato que se manifiesta en dos niveles. A nivel de tokenización, el algoritmo *Byte Pair Encoding* (BPE) utilizado por estos modelos ha aprendido a segmentar eficientemente las estructuras sintácticas características de JSON (llaves, corchetes, comillas, dos puntos), produciendo secuencias de tokens más compactas que las obtenidas con formatos menos representados

en los datos de entrenamiento [11]. A nivel de generación, el modelo produce JSON con mayor consistencia estructural y menor tasa de errores de formato que otros formatos de serialización, precisamente porque ha internalizado los patrones sintácticos de JSON a partir de la exposición extensiva durante el entrenamiento. En consecuencia, la elección de JSON como formato de intercambio maximiza tanto la eficiencia de tokenización—reduciendo el consumo de tokens por solicitud—como la confiabilidad de las respuestas generadas.

El formato de entrada representa cada escenario BDD como un objeto JSON con campos `id`, `domain`, `title`, `given`, `when` y `then`. El formato de salida replica esta estructura incorporando un campo adicional, `ibdd_representation`, que contiene la traducción IBDD como una cadena de texto con saltos de línea (`\n`) para separar las cláusulas del escenario. Esta correspondencia estructural entre entrada y salida facilita la trazabilidad entre el escenario original y su traducción formal, y permite que el sistema preserve los metadatos del escenario (dominio, título) a lo largo del pipeline de procesamiento.

3.4. Construcción del Dataset

La evaluación del sistema de traducción requiere un conjunto de escenarios BDD que cubra diversidad de dominios, estructuras sintácticas y niveles de complejidad. Dado que no existe un corpus público de escenarios BDD anotados con traducciones IBDD de referencia, fue necesario construir un dataset específico para este trabajo.

3.4.1. Escenarios Canónicos de Referencia

El punto de partida para la construcción del dataset fueron los escenarios canónicos provenientes de dos dominios: el dominio de impresora industrial, extraído de los trabajos de Zameni et al. [16], y el dominio de calculadora. Estos escenarios cuentan con traducciones IBDD verificadas manualmente y cubren los patrones fundamentales del lenguaje: declaración de variables locales con y sin guardas, switches con gates de entrada y salida, asignaciones simples y compuestas, y postcondiciones con funciones de verificación. Su inclusión en el dataset cumple una doble función: sirven como ejemplos de referencia dentro del prompt de traducción (Sección 3.3) y como casos de validación cuya traducción correcta es conocida de antemano.

3.4.2. Generación Sintética de Escenarios

A partir de los escenarios canónicos, se generó un dataset sintético más amplio utilizando un modelo de lenguaje. El proceso de generación consistió en proveer al modelo los escenarios canónicos como ejemplos de referencia junto con instrucciones para producir nuevos escenarios BDD en formato Gherkin, representados como objetos JSON con la estructura estándar del sistema (campos `id`, `domain`, `title`, `given`, `when`, `then`). Se solicitaron escenarios que variaran en dominio de aplicación, complejidad de las interacciones y cantidad de pasos, manteniendo la plausibilidad funcional de las situaciones descritas.

La generación sintética mediante un LLM presenta la ventaja de producir escenarios lingüísticamente diversos—con variaciones naturales en la redacción de las cláusulas Given, When y Then—que ejercitan la capacidad del sistema de traducción para manejar formulaciones heterogéneas de un mismo tipo de interacción. Esta diversidad es particularmente relevante dado que los escenarios BDD en entornos reales exhiben una variabilidad considerable en estilo y nivel de detalle según el autor. Al mismo tiempo, la generación sintética introduce el riesgo de escenarios que, si bien son gramaticalmente correctos en Gherkin, describen situaciones funcionalmente implausibles o ambiguas, lo cual requirió una revisión manual posterior del dataset generado.

Capítulo 4

Implementación

Este capítulo describe la implementación del sistema de traducción automática BDD→IBDD. Se presenta la arquitectura general del pipeline, la definición formal de la gramática IBDD en Lark, el módulo de traducción basado en la API de OpenAI y el módulo de validación sintáctica.

4.1. Arquitectura del Sistema

El sistema implementa un pipeline de cinco etapas orquestado por la clase `BDDToIBDDPipeline`, definida en el módulo principal. Cada etapa consume la salida de la anterior y persiste sus resultados en archivos JSON intermedios, lo que permite ejecutar las etapas de manera independiente durante el desarrollo y la depuración. A continuación se describe brevemente cada etapa; las secciones posteriores de este capítulo desarrollan en detalle los módulos correspondientes.

1. **Traducción** (Sección 4.3). Recibe el archivo `Dataset.json` con los escenarios BDD en formato Gherkin y produce traducciones IBDD mediante la API de OpenAI, utilizando Structured Outputs para garantizar conformidad con el esquema JSON esperado. Las traducciones se persisten incrementalmente en `output.json`.

2. **Validación sintáctica** (Sección 4.4). Cada traducción se analiza contra la gramática formal IBDD utilizando el analizador Earley de Lark. Los escenarios que no superan la validación se identifican con información detallada del error, incluyendo la posición y el tipo de violación sintáctica. Los resultados se almacenan en `parsed_ibdd_results.json`.

3. **Validación semántica** (Sección 4.6). Los escenarios sintácticamente válidos se someten a una verificación semántica que contrasta la traduc-

ción IBDD con el escenario BDD original, evaluando la preservación de entidades, acciones y valores numéricos.

4. **Análisis de errores** (Sección 4.5). Los escenarios que fallaron en la validación sintáctica o semántica son procesados por un agente especializado—el *explainer*—que diagnostica la causa del error y genera una explicación estructurada con sugerencias de corrección.

5. **Reintento con correcciones** (Sección 4.5). Las explicaciones de error se inyectan en un prompt de reintento que solicita al LLM una nueva traducción informada por el diagnóstico previo. Las traducciones corregidas reemplazan únicamente los casos fallidos mediante una estrategia de fusión no destructiva, y el ciclo de validación se repite sobre los casos retraducidos.

El pipeline completo se implementa en Python. Los datos fluyen secuencialmente desde `Dataset.json` hasta los archivos de resultados finales, y todas las etapas operan sobre archivos JSON como formato de intercambio.

4.2. Definición de la Gramática IBDD

La gramática IBDD se especifica en formato EBNF compatible con Lark y constituye el componente central del módulo de validación. Su diseño captura la estructura formal del lenguaje IBDD definido por Zameni et al. [16], adaptada para manejar las variaciones de formato que genera el LLM.

4.2.1. Estructura de la Gramática

La gramática define un escenario IBDD como la secuencia de tres cláusulas obligatorias: Given, When y Then. El Listado 4.1 presenta las reglas estructurales principales.

Listing 4.1: Reglas estructurales de la gramática IBDD en Lark.

```
scenario: given when then

given: "GIVEN" [vars] guard
vars: var (COMMA var)*

when: "WHEN" switch+
then: "THEN" switch* guard

switch: interaction (guard | expr | assignment)*
```

```
interaction: gate [DOT var_list]
gate: /[!?][a-zA-Z][a-zA-Z0-9_]*/
var_list: var (COMMA var)*

guard: LBRACKET expr RBRACKET
```

La cláusula `given` acepta opcionalmente una lista de variables locales seguida de una guarda entre corchetes. La cláusula `when` requiere al menos un switch, mientras que `then` acepta cero o más switches seguidos de una guarda final que representa la postcondición. Cada switch se compone de una interacción—un gate con dirección (`?` para entrada, `!` para salida) y opcionalmente una lista de variables de interacción—seguida de una secuencia flexible de guardas, expresiones y asignaciones.

La regla `switch` merece atención particular. Su definición emplea una alternancia con repetición:

```
switch: interaction (guard | expr | assignment)*
```

Esta formulación permite acomodar las diversas formas en que el LLM estructura los switches. En la gramática teórica de IBDD, un switch sigue estrictamente el patrón *interacción – condición – asignación*; sin embargo, las traducciones generadas por el modelo pueden omitir la condición, presentar la asignación antes de la guarda, o incluir expresiones sin envolver en corchetes. Esta flexibilidad sintáctica es una decisión de diseño deliberada que prioriza la capacidad de analizar traducciones imperfectas sobre el rechazo estricto de variaciones menores.

4.2.2. Jerarquía de Expresiones

Las expresiones de la gramática se organizan en una jerarquía de precedencia que refleja las convenciones matemáticas estándar. El Listado 4.2 muestra esta jerarquía.

Listing 4.2: Jerarquía de expresiones en la gramática IBDD.

```
expr: or_expr
or_expr: and_expr ((OR | OR_SYMBOL) and_expr)*
and_expr: not_expr ((AND | AND_SYMBOL) not_expr)*
not_expr: (NOT | NOT_SYMBOL) not_expr | comparison
comparison: sum [op sum]
sum: product ((PLUS|MINUS) product)*
product: power ((STAR|SLASH|PERCENT) power)*
power: atom [CIRCUMFLEX atom]
```

```
atom: literal | var | func_call
     | prop_access | neg_number
     | LPAR expr RPAR
```

La disyunción tiene la menor precedencia, seguida por la conjunción, la negación, las comparaciones, las operaciones aritméticas de suma y resta, las de multiplicación, división y módulo, y finalmente la exponenciación. Los átomos constituyen las unidades indivisibles de las expresiones e incluyen literales booleanos (`true`, `false`) y numéricos, variables, llamadas a funciones (como `is_in_list(CJ, SJL)`), accesos a propiedades (`CJ.type`) y expresiones parentizadas.

4.2.3. Soporte de Operadores

La gramática acepta tanto notación Unicode como ASCII para los operadores lógicos y de comparación. La conjunción puede expresarse como $\wedge$ o `&&`, la disyunción como $\vee$ o `||`, y la negación como $\neg$ o `!`. De manera similar, la desigualdad admite $\neq$ o `!=`, y los operadores de orden $\leq$/`<=` y $\geq$/`>=`. Este soporte dual responde a la variabilidad observada en las salidas del LLM, que puede utilizar caracteres Unicode o sus equivalentes ASCII según el contexto de generación. Sin esta flexibilidad, traducciones semánticamente correctas serían rechazadas por el analizador debido a diferencias puramente notacionales.

4.2.4. Transformación del Árbol Sintáctico

El análisis sintáctico produce un árbol de derivación que se transforma en objetos del dominio mediante la clase `IBDDTransformer`, implementada como un transformador de Lark. La transformación mapea cada nodo del árbol a una de cinco clases de datos: `IBDDScenario` representa el escenario completo con variables locales, precondición, switches de When y Then, y postcondición; `IBDDSwitch` encapsula una interacción con su condición y asignaciones; `IBDDInteraction` modela un gate con sus variables; `IBDDAssignment` representa una asignación de valor a variable o propiedad; e `IBDDExpression` captura expresiones tipadas con sus subexpresiones en una estructura recursiva. Esta representación intermedia facilita la inspección programática de las traducciones y la generación de reportes de validación estructurados.

4.3. Módulo de Traducción

El módulo de traducción se implementa en la clase `TranslationService` y gestiona la comunicación con la API de OpenAI para producir traducciones IBDD a partir de escenarios BDD. El diseño del módulo se organiza en torno a tres aspectos: la garantía estructural de las respuestas mediante *Structured Outputs*, la inferencia dinámica del esquema JSON, y la estrategia de procesamiento de escenarios.

4.3.1. Structured Outputs de OpenAI

El sistema utiliza la funcionalidad de *Structured Outputs* de OpenAI [9], que permite especificar un esquema JSON (*JSON Schema*) como parte de la solicitud a la API. Cuando se activa el modo `json_schema` con la opción `strict: true`, la API garantiza que la respuesta del modelo se ajustará exactamente al esquema proporcionado. Esta garantía se implementa mediante *constrained decoding*: durante la generación, el modelo descarta las secuencias de tokens que violarían el esquema antes de seleccionar el siguiente token, asegurando que el resultado contenga exactamente los campos especificados con los tipos correctos.

El uso de Structured Outputs en este sistema presenta dos ventajas concretas. La primera es la eliminación de errores de formato: sin esta restricción, el modelo podría devolver JSON malformado, incluir campos adicionales no solicitados, o envolver la respuesta en bloques de código Markdown, lo cual requeriría lógica de post-procesamiento frágil y propensa a errores. La segunda ventaja es la garantía de presencia del campo `ibdd_representation`, que es donde el modelo deposita la traducción IBDD para cada escenario. Al declarar este campo como obligatorio en el esquema, se asegura que toda respuesta válida contenga la traducción solicitada.

Cabe señalar que Structured Outputs garantiza la corrección estructural del JSON pero no la corrección sintáctica del contenido IBDD. El campo `ibdd_representation` contiene una cadena de texto cuyo contenido—la traducción IBDD—requiere validación adicional mediante el analizador sintáctico descrito en la sección anterior. Esta distinción entre validación de formato (a cargo de Structured Outputs) y validación de contenido (a cargo del parser Earley) es fundamental en la arquitectura del sistema.

4.3.2. Inferencia Dinámica del Esquema

El esquema JSON que se envía a la API no se define estáticamente, sino que se infiere dinámicamente a partir de la estructura de los datos de

entrada mediante el método `create_response_schema`. Este método recorre recursivamente el JSON de entrada, determina el tipo de cada campo (`string`, `integer`, `boolean`, `array`, `object`) y construye un esquema compatible con JSON Schema que replica la estructura observada. Adicionalmente, el método inyecta automáticamente el campo `ibdd_representation` de tipo `string` si este no está presente en los datos de entrada, asegurando que el esquema resultante siempre incluya el campo de salida requerido para la traducción.

Para entradas de tipo arreglo—el caso habitual, donde se procesa un conjunto de escenarios—el esquema resultante envuelve los elementos en un objeto con un campo `items` de tipo arreglo. Esta envoltura responde a un requisito técnico de la API de OpenAI, que exige que el esquema raíz sea de tipo objeto. El servicio de traducción deshace esta envoltura al recibir la respuesta, extrayendo de manera transparente el arreglo de escenarios traducidos.

La inferencia dinámica permite que el sistema se adapte a variaciones en la estructura del *dataset* de entrada sin requerir modificaciones en el código. Si se agregan campos al JSON de entrada (por ejemplo, notas o metadatos adicionales), el esquema inferido los incorporará automáticamente y el modelo los preservará en la salida.

4.3.3. Procesamiento de Escenarios

El servicio procesa los escenarios de manera individual: cada escenario BDD se envía como una solicitud independiente a la API y su traducción se persiste de manera incremental en el archivo de salida. Esta estrategia de procesamiento individual—en contraposición al envío de todos los escenarios en una única solicitud—responde a dos consideraciones.

La primera es la reducción del costo de las llamadas a la API. El envío del dataset completo en una única solicitud implicaría un prompt de entrada de gran tamaño, ya que cada escenario adicional incrementa el número de tokens de contexto. Dado que la API de OpenAI factura por cantidad de tokens procesados, tanto de entrada como de salida, y que el costo por token de salida es superior al de entrada, el procesamiento individual minimiza el contexto por solicitud y reduce el costo total. Además, las solicitudes con contextos extensos presentan mayor probabilidad de respuestas truncadas o degradadas en calidad cuando el modelo debe mantener coherencia a lo largo de una salida muy extensa.

La segunda consideración es la resiliencia ante interrupciones: dado que cada traducción se persiste de manera incremental en el archivo de salida, si el proceso se detiene por un error de red, agotamiento de la cuota de la API u otra causa, las traducciones completadas se preservan y no es necesario

reprocesar todo el conjunto de datos.

El módulo implementa un mecanismo de reintentos con *exponential backoff* para manejar errores transitorios de la API, particularmente los errores de límite de tasa (código HTTP 429). Ante un error, el sistema espera un intervalo que se duplica en cada reintento ($t_i = t_{\text{base}} \cdot 2^{i-1} + \epsilon$, donde ϵ es una perturbación aleatoria uniforme), hasta un máximo de cinco intentos. Este mecanismo permite procesar conjuntos de datos extensos sin interrupciones por limitaciones temporales de la API.

La temperatura del modelo se configura en 0,7, un valor que balancea la diversidad de las traducciones con la consistencia sintáctica. Valores más bajos producirían traducciones más determinísticas pero potencialmente repetitivas ante escenarios similares; valores más altos introducirían mayor variabilidad con riesgo de desviaciones sintácticas. El modelo utilizado es configurable mediante parámetros de línea de comandos, lo que permite evaluar diferentes versiones del modelo sin modificar el código fuente.

4.4. Módulo de Validación Sintáctica

El módulo de validación instancia la clase `IBDDParser`, que encapsula el analizador Earley de Lark. El parser se configura con dos opciones relevantes: resolución automática de ambigüedades (`ambiguity='resolve'`) y propagación de posiciones (`propagate_positions=True`). La primera opción indica al analizador que seleccione automáticamente la derivación más simple ante una ambigüedad, evitando la necesidad de intervención manual. La segunda habilita la generación de mensajes de error que incluyen la línea y columna exactas donde se detectó la violación sintáctica, información útil para diagnosticar problemas en las traducciones.

Antes del análisis, cada texto IBDD se somete a un preprocesamiento que normaliza los caracteres de escape (`\n` a saltos de línea reales), elimina líneas vacías y colapsa espacios múltiples dentro de cada línea. Este preprocesamiento es necesario porque las traducciones generadas por el LLM representan los saltos de línea como secuencias de escape dentro de cadenas JSON, y el analizador Earley requiere el texto con saltos de línea reales para aplicar las reglas de la gramática que dependen de la separación de cláusulas.

La validación opera en modo por lotes: el sistema procesa secuencialmente todos los escenarios de un archivo JSON, registrando para cada uno si el análisis fue exitoso o, en caso de fallo, el mensaje de error del analizador. Los resultados se persisten en un archivo JSON que asocia cada escenario con su estado de validación (`valid: true/false`), el dominio, el título y, cuando corresponde, el mensaje de error y la representación parseada del escenario.

Este informe estructurado sirve como insumo para las etapas posteriores del pipeline.

El módulo incluye además un analizador de respaldo (*fallback parser*) basado en expresiones regulares que se activa cuando el analizador Earley no logra procesar un texto IBDD. Este analizador alternativo extrae los componentes principales del escenario—variables de la cláusula Given, gates de la cláusula When y postcondición de la cláusula Then—mediante patrones de coincidencia, produciendo una representación parcial pero útil para el diagnóstico de errores.

4.5. Módulo de Corrección Iterativa

Cuando el analizador sintáctico detecta que una traducción IBDD no es conforme a la gramática, el pipeline activa un ciclo de corrección que involucra tres etapas: identificación de los casos fallidos, análisis automatizado de los errores mediante un agente explicador, y reintento de la traducción con contexto del error. Este ciclo constituye el mecanismo central de autocorrección del sistema y opera de manera no destructiva sobre las traducciones existentes.

4.5.1. Identificación de Casos Fallidos

Al finalizar la validación sintáctica, el orquestador del pipeline cruza los resultados de validación con las traducciones originales para construir un expediente completo de cada caso fallido. Para cada escenario cuyo campo `valid` es `false`, el sistema recopila cuatro elementos: el identificador del caso, el escenario BDD original (cláusulas Given, When y Then en lenguaje natural), la traducción IBDD que generó el error, y el mensaje de error producido por el analizador Earley, que incluye la posición exacta (línea y columna) y el tipo de token inesperado. Esta información constituye el insumo que alimenta al agente explicador de errores.

4.5.2. Análisis de Errores

El análisis de errores se implementa en la clase `IBDDErrorExplainer`, un agente especializado que utiliza el LLM para interpretar los mensajes de error del parser y producir diagnósticos estructurados. A diferencia del módulo de traducción, que opera con una temperatura de 0,7, el explicador se configura con una temperatura de 0,3. Este valor más bajo favorece respuestas determinísticas y analíticas, apropiadas para una tarea de diagnóstico donde la

creatividad no es deseable.

El agente explicador opera con un prompt de sistema que incluye la gramática IBDD de referencia y un catálogo de patrones de error frecuentes: corchetes faltantes en guardas o condiciones, sintaxis de gate incorrecta (confusión entre `?` y `!`), asignaciones ausentes, expresiones mal formadas, saltos de línea incorrectos y postcondiciones faltantes. Este catálogo permite que el modelo enfoque su análisis en las categorías de error más probables.

Para cada caso fallido, el explicador construye un prompt de análisis que presenta al modelo el escenario BDD original, la traducción IBDD que falló y el mensaje de error del parser, solicitando un diagnóstico estructurado. La respuesta se obtiene mediante Structured Outputs con un esquema que define cinco campos obligatorios: `error_type` (clasificación del error, por ejemplo "corchetes faltantes" o "gate inválido"), `error_location` (posición exacta dentro del texto IBDD), `explanation` (descripción de la discrepancia entre lo esperado por el parser y lo encontrado), `correction_suggestion` (fragmento IBDD corregido o sugerencia concreta) y `hints` (lista de recomendaciones adicionales). El uso de Structured Outputs garantiza que todo diagnóstico contenga estos cinco campos con los tipos de datos correctos, facilitando su procesamiento automatizado en la etapa siguiente.

4.5.3. Reintento con Contexto de Error

El reintento de traducción utiliza un prompt especializado que extiende el prompt de traducción inicial con información del error. El prompt de reintento contiene las mismas cinco secciones del prompt original—contexto, gramática, ejemplos, reglas y formato—pero incorpora al inicio una sección adicional de análisis de error, precedida por un encabezado que indica al modelo que se encuentra en modo de corrección. Esta sección se inyecta dinámicamente mediante un *placeholder* {`error_analysis`} que el sistema reemplaza con el diagnóstico formateado del caso específico.

El formato del diagnóstico inyectado incluye el escenario BDD original, la traducción previa que falló, el error del parser, el análisis completo del explicador (tipo, ubicación, explicación y sugerencia de corrección) y las recomendaciones adicionales. De este modo, el modelo de traducción recibe el contexto completo del fallo y puede aplicar la corrección de manera informada. El prompt de reintento añade además una lista de verificación final que instruye al modelo a confirmar, antes de emitir la respuesta, que la corrección aborda el error específico identificado, que todos los corchetes están correctamente ubicados, que la sintaxis de gates es válida y que la traducción mantiene la correspondencia semántica con el escenario BDD original.

El procesamiento de reintentos opera de manera individual: cada caso

fallido se reenvía como una solicitud independiente a la API, utilizando el mismo mecanismo de Structured Outputs y reintentos con *exponential backoff* del módulo de traducción inicial. Esta independencia permite que el fallo de un reintento no afecte la corrección de los demás casos.

4.5.4. Fusión No Destructiva y Re-validación

Las traducciones corregidas se integran al conjunto de resultados mediante una estrategia de fusión no destructiva. El sistema carga las traducciones originales, construye un mapa indexado por identificador de caso con las traducciones corregidas, y recorre secuencialmente las traducciones originales: para cada caso cuyo identificador coincide con una corrección, se reemplaza la traducción original por la corregida; los casos que no presentaron errores se preservan intactos. Este diseño garantiza que las traducciones exitosas nunca se sobrescriban como efecto colateral del proceso de corrección.

Tras la fusión, el pipeline ejecuta una re-validación sintáctica sobre el archivo de traducciones actualizado, aplicando el mismo analizador Earley utilizado en la validación inicial. Esta re-validación cumple dos funciones: confirmar que las correcciones resolvieron efectivamente los errores de parsing, e identificar casos donde el reintento no logró producir una traducción conforme. Los resultados de la re-validación se persisten en el mismo archivo de validación, actualizando el estado de cada caso.

Las etapas de análisis de errores y reintento se clasifican como no críticas dentro del pipeline: si alguna de ellas falla—por ejemplo, por un error de la API o un agotamiento de la cuota—el pipeline continúa con las traducciones originales y emite una advertencia. Esta decisión se fundamenta en que es preferible contar con traducciones parcialmente correctas (las exitosas de la primera pasada) que interrumpir todo el proceso por un fallo en la corrección de los casos problemáticos.

4.6. Módulo de Validación Semántica

La validación sintáctica descrita en secciones anteriores verifica que las traducciones IBDD se ajusten a la gramática formal, pero no evalúa si el contenido de la traducción preserva el significado del escenario BDD original. Una traducción puede ser sintácticamente correcta y al mismo tiempo semánticamente deficiente: por ejemplo, podría omitir una entidad mencionada en el escenario, utilizar un gate de salida donde el BDD describe una acción del usuario, o perder un valor numérico relevante para una postcondición. El módulo de validación semántica aborda esta limitación mediante un enfoque

de verificación en múltiples capas.

4.6.1. Arquitectura Multi-capa

El validador semántico se implementa en la clase `SemanticValidator` y opera exclusivamente sobre los escenarios que superaron la validación sintáctica, ya que intentar evaluar la semántica de un texto que no se ajusta a la gramática carecería de fundamento. El diseño contempla tres capas de validación progresivamente más sofisticadas, donde cada capa aplica un nivel de análisis más profundo. Las capas operan de forma secuencial con una estrategia de *fail-fast*: si una capa determina que la traducción es inválida, las capas posteriores no se ejecutan, evitando el costo computacional de análisis innecesarios.

Cada capa produce un resultado tipado que incluye un veredicto booleano, un puntaje de confianza en el rango $[0, 1]$, un identificador de la capa que emitió el veredicto, una lista de problemas detectados y un diccionario de detalles específicos de la evaluación. Esta estructura uniforme permite agregar los resultados de las tres capas en un informe consolidado por escenario.

4.6.2. Capa 1: Validación por Checklist

La primera capa implementa una verificación basada en la extracción y cotejo de elementos clave entre el escenario BDD original y la traducción IBDD. Esta capa opera sin recurrir al LLM, lo que la hace instantánea y sin costo.

El proceso de validación comienza con la extracción de tres tipos de elementos del texto BDD. Las entidades se identifican mediante heurísticas léxicas que combinan cuatro estrategias: extracción de sustantivos precedidos por artículos ("a job file" identifica "file"), detección de sustantivos recurrentes (palabras que aparecen dos o más veces en el escenario), reconocimiento de variables capitalizadas, y coincidencia con un vocabulario de sustantivos técnicos frecuentes en dominios BDD (como "account", "balance", "cart", "transaction"). Las acciones se extraen principalmente de la cláusula When mediante un diccionario de verbos de acción comunes en escenarios BDD ("submit", "add", "transfer", "click") complementado con detección de formas verbales por sufijos. Los valores numéricos se extraen mediante coincidencia de patrones de números enteros y decimales.

Una vez extraídos los elementos, el validador busca su presencia en el texto IBDD normalizado. La búsqueda de entidades incorpora flexibilidad para acomodar las convenciones de IBDD: se busca la entidad literal, como parte de nombres de funciones o propiedades ("`.entity`", "`entity(`"), en formas

singular y plural, y como inicial en las variables capitalizadas del IBDD (por ejemplo, la entidad "job" se considera presente si existe una variable como `JF` que contiene la inicial "J"). Las acciones se buscan como componentes de nombres de gates (`?transfer`, `!add`) o en forma *snake_case*.

El puntaje de confianza se calcula como la proporción de elementos presentes sobre el total de elementos extraídos. El umbral de validación se establece en 0,6, lo que tolera hasta un 40 % de elementos no encontrados. Este umbral relativamente permisivo responde al hecho de que IBDD utiliza abreviaturas y convenciones de nomenclatura que dificultan la coincidencia directa con el texto en lenguaje natural.

4.6.3. Capa 2: Consistencia Numérica

La segunda capa, prevista para una iteración futura, verificará la consistencia de los valores numéricos y las operaciones aritméticas entre el escenario BDD y su traducción IBDD. El objetivo es detectar errores como la omisión de valores numéricos en las guardas, operaciones aritméticas incorrectas en las asignaciones, o postcondiciones que no reflejan los cálculos descritos en el escenario original.

4.6.4. Capa 3: Juez LLM

La tercera capa, también prevista para desarrollo futuro, empleará el propio modelo de lenguaje como evaluador semántico. El LLM recibirá el escenario BDD original y la traducción IBDD, y producirá una evaluación estructurada que cubra la preservación de entidades, la representación de precondiciones, la correspondencia de acciones con gates, la corrección de los cambios de estado y la coherencia de las postcondiciones. A diferencia de las capas anteriores, esta evaluación capturará relaciones semánticas complejas que las heurísticas léxicas no pueden detectar, como la equivalencia entre la frase "el usuario agrega el producto al carrito" y el gate `?add_to_cart.p,sc`. El costo de esta capa—una llamada a la API por escenario—justifica su posición como última etapa del pipeline, ejecutándose solo sobre los escenarios que superaron las verificaciones previas.

Capítulo 5

Evaluación

5.1. Preguntas de Investigación

5.2. Diseño Experimental

5.3. Dataset

5.4. Métricas

5.5. Resultados

5.6. Análisis

Capítulo 6

Discusión

6.1. Interpretación de Resultados

6.2. Limitaciones

6.3. Amenazas a la Validez

Capítulo 7

Conclusiones y Trabajo Futuro

7.1. Trabajo Futuro

Bibliografía

[1] Laura Brandán Briones. "Theories for Model-based Testing: Real-time and Coverage". Tesis doct. Enschede, The Netherlands: University of Twente, 2007.

[2] Cucumber Ltd. *Gherkin Reference*. `https://cucumber.io/docs/gherkin/reference/`. Accessed: 2025. 2024.

[3] Lars Frantzen, Jan Tretmans y René de Vries. "A Symbolic Framework for Model-Based Testing". En: *Formal Approaches to Software Testing and Runtime Verification (FATES/RV 2006)*. Vol. 4262. Lecture Notes in Computer Science. Springer, 2006, págs. 40-54.

[4] Lars Frantzen, Jan Tretmans y Tim A. C. Willemse. "Test Generation Based on Symbolic Specifications". En: *Formal Approaches to Software Testing (FATES 2004)*. Vol. 3395. Lecture Notes in Computer Science. Berlin, Heidelberg: Springer, 2005, págs. 1-15.

[5] goodmami. *python-parsing-benchmarks*. 2026. URL: `https://github.com/goodmami/python-parsing-benchmarks` (visitado 28-01-2026).

[6] Shanthi Karpurapu et al. "Comprehensive Evaluation and Insights into the Use of Large Language Models in the Automation of Behavior-Driven Development Acceptance Test Formulation". En: *IEEE Transactions on Software Engineering* (2024).

[7] Lark Parser Project. *Lark: a parsing toolkit for Python*. 2026. URL: `https://github.com/lark-parser/lark` (visitado 28-01-2026).

[8] Dan North. *Introducing BDD*. `https://dannorth.net/blog/introducing-bdd/`. Originally published in Better Software magazine, March 2006. 2006.

[9] OpenAI. *Introducing Structured Outputs in the API*. `https://openai.com/index/introducing-structured-outputs-in-the-api/`. Accessed: 2025. 2024.

[10] Python Poetry Team. *poetry-core*. 2026. URL: `https://github.com/python-poetry/poetry-core` (visitado 28-01-2026).

[11] Rico Sennrich, Barry Haddow y Alexandra Birch. “Neural Machine Translation of Rare Words with Subword Units”. En: *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (ACL)*. Berlin, Germany: Association for Computational Linguistics, 2016, págs. 1715-1725.

[12] Carlos Solís y Xiaofeng Wang. “A Study of the Characteristics of Behaviour Driven Development”. En: *2011 37th EUROMICRO Conference on Software Engineering and Advanced Applications (SEAA)*. Oulu, Finland: IEEE, 2011, págs. 383-387.

[13] Jan Tretmans. “Model Based Testing with Labelled Transition Systems”. En: *Formal Methods and Testing*. Vol. 4949. Lecture Notes in Computer Science. Heidelberg: Springer, 2008, págs. 1-38.

[14] Mark Utting, Alexander Pretschner y Bruno Legeard. “A Taxonomy of Model-Based Testing Approaches”. En: *Software Testing, Verification and Reliability* 22.5 (2012), págs. 297-312.

[15] Vyper Team. *Vyper: Pythonic smart contract language for the EVM*. 2026. URL: `https://github.com/vyperlang/vyper` (visitado 28-01-2026).

[16] Tahmineh Zameni et al. “An Intermediate Language to Integrate Behavior-Driven Development Scenarios and Model-Based Testing”. En: *2024 IEEE International Conference on Software Analysis, Evolution and Reengineering - Companion (SANER-C)*. IEEE, 2024.

[17] Tahmineh Zameni et al. “From BDD Scenarios to Test Case Generation”. En: *2023 IEEE International Conference on Software Testing, Verification and Validation Workshops (ICSTW)*. IEEE, 2023.